

[0/3 ~ 9]

[~ 1]

$$X_1, \dots, X_n \sim P$$

Рассм \hat{P} — эмп. распр. с $F_n(x) = \frac{1}{n} \sum I\{X_i \leq x\}$

Найдём $\text{cov}(\hat{F}_n(x), \hat{F}_n(y)) =$, попоху $x \leq y$

$$= \frac{1}{n^2} \text{cov}\left(\sum I\{X_i \leq x\}, \sum I\{X_i \leq y\}\right) =$$

$$= \frac{1}{n^2} \left[\sum_{i \neq j} \text{cov}(I\{X_i \leq x\}, I\{X_j \leq y\}) + \sum_k \text{cov}(I\{X_k \leq x\}, I\{X_k \leq y\}) \right] \textcircled{=}$$

$$= P(X_i \leq x, X_j \leq y) - P(X_i \leq x)P(X_j \leq y)$$

$$= 0, \text{ т.к. } X_i \text{ и } X_j \text{ независ.}$$

$$\textcircled{=} \frac{1}{n^2} \sum_{k=1}^n P(X_k \leq x, X_k \leq y) - P(X_k \leq x)P(X_k \leq y) =$$

$$= \frac{1}{n^2} \sum P(X_k \leq x) - P(X_k \leq x)P(X_k \leq y) =$$

$$= \frac{1}{n^2} \sum P(X_k \leq x)P(X_k \leq y) = \frac{1}{n} P(X_1 \leq x)P(X_1 \leq y)$$

W2 X_1, \dots, X_n - выборка из генер. распр. ρ .

$$\gamma = \frac{1}{\sigma^4} E(X-a)^4 - 3, \text{ где } \sigma^2 = D_X = E(X-a)^2$$

коэф.
эксц.

$$\hat{\gamma} = \frac{1}{\hat{\sigma}^4} \int_{\mathbb{R}} (x-\hat{a})^4 dF_n(x) - 3 = \frac{1}{n\hat{\sigma}^4} \sum_{i=1}^n (x_i - \hat{a})^4$$

$$\text{где } \hat{\sigma}^2 = \overline{X^2} - \bar{X}^2$$

$$\hat{a} = \bar{X}$$

Схема бутстрэпа для оценки распр. получ. однокл.

Т.е. для подсчёта $D_{\hat{\rho}_n} \hat{\gamma}$

1) В раз генерируем

$$i_1, \dots, i_n \sim U\{1, \dots, n\} \Rightarrow X^* = (X_{i_1}^*, \dots, X_{i_n}^*) \text{ - бутстреп. выборка}$$

Назовём выборки

$$X_1^* \dots X_B^*$$

2) Посчитаем на выборках $\hat{\gamma}_1^* \dots \hat{\gamma}_B^*$ Полагая $\hat{\gamma}_1^* \dots \hat{\gamma}_B^*$
величины

3) найдём сред. дисперс.

$$D_{\hat{\rho}_n} \hat{\gamma} \approx \frac{1}{B} \sum_{b=1}^B \hat{\gamma}_b^{*2} - \left(\frac{1}{B} \sum_{b=1}^B \hat{\gamma}_b^* \right)^2$$

3 x_1, \dots, x_n - разные выборы
 x_1^*, \dots, x_n^* - нек. дублир. вхо. по ней

Обозначим за K_i - кол-во вхождений x_i в дублир. выборку

$$P(K_i > 0) = 1 - P(K_i = 0) = \left[1 - \left(\frac{n-1}{n} \right)^n \right]$$

Рассм. Y_1, \dots, Y_n - случ. величины

$$Y_i \sim \text{Берн} \left(1 - \left(\frac{n-1}{n} \right)^n \right)$$

$\sum_{i=1}^n Y_i$ - число uniq. элементов в дублир. выбо.

$$E \sum_{i=1}^n Y_i = \left[n \left(1 - \left(\frac{n-1}{n} \right)^n \right) \right]$$

Посмотрим куда скор. величина $1 - \left(\frac{n-1}{n} \right)^n$

$$\left(\frac{n-1}{n} \right)^n = \left(1 - \frac{1}{n} \right)^n \rightarrow e^{-1} \approx 0,367$$

Откуда $1 - \left(\frac{n-1}{n} \right)^n \rightarrow 1 - e^{-1} \approx 0,633$

Значит в среднем при добавлении n , рога uniq. элементов: 63,3%

$$\boxed{\text{н.ч.}} \quad X_1, \dots, X_n \sim U[0, \theta]$$

$$\hat{\theta} = X_{(n)}$$

Почему метод оценки распр. $\hat{\theta}$ работ. плохо?

① Проблем что значен. "плохо" работает.

Пусть $X_1^* \dots X_B^*$ — бутстр. выборка

$X_{(n)}^1 \dots X_{(n)}^B$ — соотв. максимумы

$$\text{Заметим } X_{(n)}^b \leq X_{(n)}$$

Причем более чем в 30% случаев $X_{(n)}$ не попадает в бутстр. выборку

$$\text{В таких случаях } X_{(n)}^b \leq X_{(n-1)}$$

Иными словами, если изнач. выборка чуть-чуть неграждан

(иными словами $X_{(n)} \leq \frac{n}{n+1}$), получим:

$$E_{\text{boots}} X_{(n)} = \left(\sum_b X_{(n)}^b \right) \cdot \frac{1}{B} \ll E X_{(n)}$$

Ан-ко с другими параметрами распр:

$$P_{\text{boot}} X_{(n)}, \quad K, \quad \gamma$$

② Бутстреп лучше работает с оценками воле свержих,

т.к. все выборка непоср. влияет на оценку, кодобе

бутстреиные оценки в обе стороны от настоящей.

$$\hat{\theta} \geq \frac{2}{3} \left(-\frac{1}{n-1} \right) + \frac{2}{9} \left(-\frac{1}{n} \right) + \frac{2}{27} \left(-\frac{1}{n-1} \right)$$

№5 x_1, \dots, x_n — выборка | x_1^*, \dots, x_n^* — отсчеты

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i^*$$

① $D\left(\frac{1}{n} \sum_{i=1}^n x_i^* \mid x_1, \dots, x_n\right) = \frac{1}{n^2} D\left(\sum_{i=1}^n x_i^* \mid x_1, \dots, x_n\right)$ ②

$$E\left(\sum_{i=1}^n x_i^* \mid x_1, \dots, x_n\right) = \sum E(x_i^* \mid x_1, \dots, x_n) = n \bar{x}$$

$$E\left(\left(\sum_{i=1}^n x_i^*\right)^2 \mid x_1, \dots, x_n\right) = \sum_{i,j} E(x_i^* x_j^* \mid x_1, \dots, x_n) = n \bar{x}^2$$

$$= n(n-1) \sum_{a,b} \frac{x_a x_b}{n^2} = \frac{(n-1)}{n} \sum_{a,b} x_a x_b + n \bar{x}^2$$

$$= \frac{n-1}{n} \left(\sum x_i\right)^2 + n \bar{x}^2 = n(n-1) \bar{x}^2 + n \bar{x}^2$$

$$\textcircled{=} \frac{1}{n^2} (n(n-1) \bar{x}^2 + n \bar{x}^2 - n^2 \bar{x}^2) = \frac{1}{n} \bar{x}^2 - \frac{1}{n} \bar{x}^2 =$$

$$= \frac{\bar{x}^2 - \bar{x}^2}{n}$$

② $D\left(\frac{1}{n} \sum_{i=1}^n x_i^*\right) = \frac{1}{n^2} D\left(\sum_{i=1}^n x_i^*\right)$ ③

$$E\left(\sum_{i=1}^n x_i^*\right) = E\left(E\left(\sum_{i=1}^n x_i^* \mid x_1, \dots, x_n\right)\right) = n E x_1$$

$$E\left(\left(\sum_{i=1}^n x_i^*\right)^2\right) = E\left(E\left(\left(\sum_{i=1}^n x_i^*\right)^2 \mid x_1, \dots, x_n\right)\right) = n(n-1)(E x)^2 + n E x^2$$

$$\textcircled{=} \frac{1}{n^2} (n(n-1) (E x)^2 + n E x^2 - n^2 (E x)^2)$$

$$= \frac{D x}{n}$$

$$\text{[a6]} \quad x = \{1, 2, 3, 4\}$$

$$P_\theta = P(1) = \theta, \quad P(2) = \theta, \quad P(3) = 2\theta, \quad P(4) = 1 - 4\theta$$

$$H_0: p \in \{P_\theta \mid \theta \in (0, \frac{1}{4})\}$$

Воспольз. крит. хи-квадрат (однородности):

$$\text{Найти } \hat{\theta} \text{ из } \sum \mu_j \ln p_j(\theta) \rightarrow \max$$

$$f(\theta) = \underline{1010} \cdot \ln \theta + \underline{2200} \cdot \ln \theta + \underline{950} \cdot \ln 2\theta + \underline{840} \cdot \ln(1-4\theta)$$

$$f' = \frac{1010}{\theta} + \frac{2200}{\theta} + \frac{950}{2\theta} \cdot 2 + \frac{840}{1-4\theta} \cdot (-4) = 0$$

$$4160 \cdot (1-4\theta) - 3360 \cdot \theta = 0$$

$$\hat{\theta} = \frac{26}{125} < \frac{1}{4}$$

$$\chi^2 = \frac{\left(1010 - 5000 \cdot \frac{26}{125}\right)^2}{5000 \cdot \frac{26}{125}} + \frac{\left(2200 - 5000 \cdot \frac{26}{125}\right)^2}{5000 \cdot \frac{26}{125}} + \frac{\left(950 - 5000 \cdot \frac{52}{125}\right)^2}{5000 \cdot \frac{52}{125}} + \frac{\left(840 - 5000 \cdot \frac{21}{125}\right)^2}{5000 \cdot \frac{21}{125}}$$

$$= \frac{(1010 - 1040)^2}{1040} + \frac{(2200 - 1040)^2}{1040} + \frac{(950 - 2080)^2}{2080} + \frac{(840 - 840)^2}{840}$$

$$= \frac{1800 + 1300 + 1276900}{2080} = 615,625$$

$$\text{Критерий } \left\{ \chi \geq \chi_{4-1-1, 0,95}^2 \right\}$$

отб-л:

$$\left\{ \chi \geq 6 \right\} \Rightarrow \text{ОТВЕРГАЕМ} \quad (p\text{-value} \approx 0)$$

(24)

Пусть имеем P_1 и P_2 — рвд. изл. и аспр.

Им соотв. F_1 и F_2 — рвд. функции
распр.

$$P(P_2) = P_2(X \in S) \rightarrow 1 \quad \text{— уел. рож-ва.}$$

$$a) \text{ критерий: } S = \left\{ \limsup_{n \rightarrow \infty} \sup_{x \in R} |\hat{F}_n(x) - F_2(x)| \geq C_\alpha \right\}$$

$$F_1 \neq F_2 \Rightarrow \exists x = x_0, \text{ где д.о.о. } \underline{F_2 > F_1 + \varepsilon}, \quad \varepsilon > 0.$$

Заметим по теор. Гливенко — Кантелли для почти всех x ~~восходит~~

$$\exists N \quad \forall n \geq N: |\hat{F}_n(x) - F_2(x)| < \frac{\varepsilon}{2}$$

$$\text{А значит на } x = x_0 \quad \underline{F_2 > \hat{F}_n + \frac{\varepsilon}{2}} \quad \text{при } n \geq N$$

$$\text{Тогда } \sup |\hat{F}_n - F_2| \geq \frac{\varepsilon}{2}$$

$$\text{Тогда } \limsup_{n \rightarrow \infty} \sup |\hat{F}_n - F_2| \geq C_\alpha$$

для раст. больш. n .

$$\text{Им } P(\limsup_{n \rightarrow \infty} \sup |\hat{F}_n - F_2| \geq C_\alpha) = 1 \quad \text{при } n \geq N$$

и т.д.

Доказ-ем $\beta(p_i) = P_2(x \in S) \rightarrow 1$

б) Критерий хи-квдрат:

$$\left\{ \sum_{j=1}^k \frac{(\mu_j - n p_j^{(1)})^2}{n p_j^{(1)}} \geq \chi_{k-1, 1-\alpha}^2 \right\}$$

Пусть $P_2(x_i \in B_j) = p_j^{(2)}$

$P_1(x_i \in B_j) = p_j^{(1)}$

Пусть с.о.о. $p_1^{(1)} \neq p_1^{(2)}$ (и также с.о.о. $p_1^{(2)} > p_1^{(1)}$)

х-б-се $P\left(\frac{(\mu_1 - n p_1^{(1)})^2}{n p_1^{(1)}} \geq c\right) \rightarrow 1$, $c := \chi_{k-1, 1-\alpha}^2$

где $\mu_i = \# \{i | x_i \in B_j\}$ и $P(B_j) = p_j^{(2)}$

~~$P(\mu_1 - n p_1^{(1)})^2 \geq c \text{ и } p_1^{(1)}$~~

$P((\mu_1 - n p_1^{(1)})^2 \geq c \text{ и } p_1^{(1)})$

Выполн. по ЗОЧ
 $\mu_1 \sim \text{Bin}(n, p_1^{(2)})$
 $E \mu_1 = n p_1^{(2)} > n \left(\frac{p_1^{(2)} + p_1^{(1)}}{2}\right)$

Значит $\delta < 1$. Заметим, что для раст. больших n :

$P\left(\mu_1 > n \left(\frac{p_1^{(2)} + p_1^{(1)}}{2}\right)\right) \geq \delta$ (т.е. почти всегда)

$P\left(\mu_1 - n p_1^{(1)} > n \frac{p_1^{(2)} - p_1^{(1)}}{2}\right) \geq \delta$

$P\left((\mu_1 - n p_1^{(1)})^2 > n^2 \cdot z\right) \geq \delta$, $z := \frac{p_1^{(2)} - p_1^{(1)}}{2}$

А значит для раст. большого n (т.к. правая часть квадратируется)

$P(|\mu_1 - n p_1^{(1)}| \geq c \text{ и } p_1^{(1)}) \geq \delta$

с.о.о. $p_1^{(1)} < p_1^{(2)}$

Формулировки:

Критерии согласия - те, что проверяют принадлежность
известной классу распр (напр. $\{P_0\}$ или нормальн
или гамма-р.)

• Теорема Колмогорова

$X = (X_1, \dots, X_n)$ - выборка из незав. распр

$$H_0: F = F_0$$

$$D_n = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F_0(x)| \text{ - статистика критерия}$$

$\sqrt{n} D_n \xrightarrow{d} Z \sim K$ - распр Колм., если F_0 - непрерыв.

Опр: \hat{P}_n наз-ся эмпер. распр. по выборке X ,

$$\text{если } \forall B \in \mathcal{B} : \hat{P}_n(B) = \frac{1}{n} \sum_{i=1}^n I\{X_i \in B\}$$

• Теор. Глivenко-Кантелли

Если F - ф.р. для P и $X = (X_1, \dots, X_n)$ - в.о. из распр P

$$\text{то } D_n = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{a.s.} 0$$

• Критерий Колмогорова

$\{\sqrt{n} D_n \geq C_\alpha\}$, где C_α - $(1-\alpha)$ квантил
 K -распр. Колм.

• Критерий хи-квадрат.

$X = (X_1, \dots, X_n)$ - в.о. из незав. распр P , $X_i \in \mathcal{X}$

$$H_0: P = P_0$$

Разложение $\mathcal{X} = \bigcup_{j=1}^k B_j$, статистика: $\hat{\chi}^2 = \sum_{j=1}^k \frac{(n_j - np_j^0)^2}{np_j^0}$

$$\text{Критерий: } \{\hat{\chi}^2 \geq \chi_{k-1}^2, 1-\alpha\}$$

Теорема Пирсона
 $\hat{\chi}^2 \xrightarrow{d} \chi_{k-1}^2$