

## Линейная регрессия

$X$  — выборка  $\in \mathbb{R}^{n \times d}$

$n$  — кол-во эл-тов  
 $d$  — кол-во пр-ков

$y$  — target  $\in \mathbb{R}^n$

$\hat{\theta}$  — ?

$$\hat{y} = X\hat{\theta}$$

$$\underset{\substack{\uparrow \\ n \times 1 \\ \text{случайный}}}{y} = \underset{\substack{\uparrow \\ n \times d \\ \text{не слуг.}}}{X} \underset{\substack{\uparrow \\ d \times 1 \\ \text{оц. пар-ра}}}{\theta} + \underset{\substack{\uparrow \\ n \times 1 \\ \text{случайный}}}{\varepsilon}$$

$$\text{МНК: } \text{RSS}(\theta) = \|y - X\theta\|^2 \rightarrow \min_{\theta}$$

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

качество модели?

$$R^2 = \frac{1 - \text{RSS}(\hat{\theta})}{\|y - \bar{y}\|^2} \quad - \quad \text{коэф-т детерминации}$$

$R \approx 1$  — хорошо

$R \approx 0$  — плохо

$d$  — большое  $\Rightarrow R^2$  — большой  $\Rightarrow$

$\Rightarrow$  иногда используют  $R_{adj}^2 = 1 - (1 - R^2) \frac{n-1}{n-d}$  — скорректированный

## Проблемы линейной регрессии

— Мультиколлинеарность — ситуация с (почти) 13 признаками

$\Rightarrow \det(X^T X) \approx 0$  близка к вырожденной

$\Rightarrow -\hat{\theta}$  может быть большой

— переобучение

— не единственное решение

— большая дисперсия оценок

## Признаки мультиколлинеарности

- высокая корреляция пр-ков
- регрессия значимая, пр-ки нет
- $CI = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}}$   $\lambda$  - с.з.  $X^T X$  - индекс обсл.

$CI > 30 \Rightarrow$  модель мультиколлинеарна  
 $\hookrightarrow$  **мал. константа**

- коэф. взвешивания по пр-ку  $j$

$$VIF_j = \frac{1}{1 - R_j^2}, \quad \text{где } R_j^2 - \text{коэф. детерминации в модели}$$

$y' = x_j \quad x' = x^{-j} \text{ (без } x_j)$


$VIF_j > 10 \Rightarrow$  мультиколлинеарна  
 $\hookrightarrow$  **мал. константа**

Борьба с мультиколлинеарностью

$$\begin{cases} \|y - X\theta\|^2 \rightarrow \min \\ \|\theta\|^2 \leq \mu \end{cases}$$

$$L(\lambda) = \|y - X\theta\|^2 - \lambda (\|\theta\|^2 - \mu)$$

неприятно решать



$$\|y - X\theta\|^2 + \alpha \|\theta\|^2 \rightarrow \min$$

RSS( $\theta$ )      регуляризатор

Ridge-regression

## Предобработка данных

- Стандартизация

$$x_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

← среднее по пр-ку  
← стандартное отклонение

- Центрирование

$$y_i = x_i - \bar{x}$$

Оценка

$$F(\theta) = \|y - X\theta\|^2 + \lambda \|\theta\|^2 \rightarrow \min_{\theta}$$

$$\nabla F(\theta) = 2 X^T (y - X\theta) + 2\lambda\theta = 0$$

$$- X^T y + (X^T X + \lambda) \theta = 0$$

$$(X^T X + \lambda I_d) \theta = X^T y$$

$$\hat{\theta} = (X^T X + \lambda I_d)^{-1} X^T y$$


ухудшили оценку  
избежали от переобучения

Сб-ба  $\hat{\theta}$

$\lambda = 0$  — лин. регрессия

$$\lambda \rightarrow \infty \Rightarrow \hat{\theta} \rightarrow 0$$

$$\lambda > 0 \Rightarrow \exists! \hat{\theta}$$



$$\begin{aligned} E\varepsilon &= 0 \Rightarrow E\hat{\theta} = E(X^T X + \lambda I_d)^{-1} X^T y = (X^T X + \lambda I_d)^{-1} X^T E y = \\ &= (X^T X + \lambda I_d)^{-1} X^T X \theta \quad \lambda \neq 0 \Rightarrow \text{смещ.} \end{aligned}$$

$$D\varepsilon = \sigma^2 I_n, \text{ то } Dy = D(X\theta + \varepsilon) = D\varepsilon$$

$$\begin{aligned} D\hat{\theta} &= (X^T X + \lambda I_d)^{-1} X Dy \cdot X^T (X^T X + \lambda I_d)^{-1} = \\ &= (X^T X + \lambda I_d)^{-1} X \sigma^2 X^T (X^T X + \lambda I_d)^{-1} \end{aligned}$$



Обращать матрицу сложно и долго.

Градиентный спуск

$$\nabla F(\theta) = -2x^T y + 2x^T x \theta + 2\alpha \theta = -2x^T y + 2(x^T x + \alpha I_d) \theta$$

$$\begin{aligned}\theta_{k+1} &= \theta_k - \eta \nabla F(\theta_k) = \theta_k - \eta (x^T y + (x^T x + \alpha I_d) \theta_k) = \\ &= \theta_k - \eta (x^T (x \theta_k - y) + \alpha \theta_k)\end{aligned}$$

Стохаст. град. спуск.

$$\theta_{k+1} = \theta_k - \eta \left[ \frac{n}{m} \sum_{i=1}^m (x_{ij}^T (x_{ij} \theta_k - y_{ij}) + \alpha \theta_k) \right]$$


$$I = \{i_1, \dots, i_m\} \sim \mathcal{U}\{1, \dots, m\}$$

Другая норма

$$\begin{cases} \|y - x\theta\|^2 \rightarrow \min \\ \|\theta\|_1 \leq \mu \end{cases}$$

$$L(\lambda) = \|y - x\theta\|^2 - \lambda (\|\theta\|_1 - \mu)$$

$$F(\theta) = \|y - x\theta\|^2 + \beta \|\theta\|_1 \rightarrow \min_{\theta} \quad - \text{Lasso - regression}$$



гипотеза: ответ будет в углах

Субградиент  $f = |x|$   $\partial f = \begin{cases} -1, & x < 0 \\ [-1, 1], & x = 0 \\ 1, & x > 0 \end{cases}$

Опр.  $f$  — выпуклая ф-ция, тогда ф-ция

$$P_{r_f}(p) = \operatorname{argmin}_x \left( \frac{1}{2} \|x - p\|^2 + f(x) \right) \quad \text{наз-ся} \quad \text{проксиальным оператором}$$

$$g(x, p) := \frac{1}{2} \|x - p\|^2 + f(x)$$

Утв. (δ/g)  $g(x, p)$  — выпуклая, то  $\forall p \exists! \min_x$

Утв. (δ/g)  $x$  — экстремум выпуклой ф-ции  $f \Leftrightarrow 0 \in \partial f(x)$

$$\text{ytl. } x_0 = p_{r_f}(p) \Leftrightarrow p - x_0 \in \partial f(x_0)$$

$$\blacktriangle x_0 = p_{r_f}(p) = \operatorname{argmin}_x g(x, p)$$

$$0 \in \partial g(x_0, p)$$

$$\partial_x g(x_0, p) = x - p + \partial_x f(x)$$

$$\partial_x g(x_0, p) = x_0 - p + \partial_x f(x_0)$$

$$0 \in x_0 - p + \partial_x f(x_0)$$

$$p - x_0 \in \partial_x f(x_0)$$

Регуляризация

$$\underbrace{F(\theta)}_{\text{ф-ция риска}} + \underbrace{\delta R(\theta)}_{\text{регуляризатор}} \rightarrow \min_{\theta}$$

Lasso

$$RSS(\theta) + \delta \|\theta\|_1$$

у.в.  $\theta$  — решение задачи  $\uparrow \Leftrightarrow \theta = P_{\partial R}(\theta - \nabla F(\theta))$

$$\blacktriangle x_0 := P_{\Gamma_f}(p) = \theta$$

$$f := \delta R$$

$$p := \theta - \nabla F(\theta)$$

$$\theta = P_{\Gamma_f}(p) \Leftrightarrow -\nabla F(\theta) \in \partial f(\theta) = \delta \partial R(\theta)$$

$$0 \in \nabla F(\theta) + \delta \partial R(\theta) = \partial [F(\theta) + \delta R(\theta)] \Leftrightarrow \theta - \text{реш. регр.}$$

Рассмотрим  $d = 1$  Lasso - regression

$$R(x) = |x| \quad x \in \mathbb{R}$$

$$\Pr_{\beta | x} \underbrace{(\theta - \nabla F(\theta))}_P$$

$$g(x, p) = \frac{1}{2} \|x - p\|^2 + \beta |x|$$

$$\partial_x g(x, p) = x - p + \beta \begin{cases} -1, & x < 0 \\ [-1, 1], & x = 0 \\ 1, & x > 0 \end{cases}$$

$$0 \in \partial_x g(x, p)$$

$$1) \quad x < 0$$

$$x - p - \beta = 0$$

$$x = p + \beta$$

$$p + \beta < 0$$

$$p < -\beta$$

$$2) \quad x > 0$$

$$x - p + \beta = 0$$

$$x = p - \beta$$

$$p - \beta > 0$$

$$p > \beta$$

$$3) \quad x = 0$$

$$-p + \beta [-1, 1] \ni 0$$

$$p \in [-\beta, \beta]$$

$$\theta_{k+1} = \begin{cases} \theta_k - \nabla F(\theta_k) + \beta, & \theta_k - \nabla F(\theta_k) < -\beta \\ 0, & \theta_k - \nabla F(\theta_k) \in [-\beta, \beta] \\ \theta_k - \nabla F(\theta_k) - \beta, & \theta_k - \nabla F(\theta_k) > \beta \end{cases}$$

крас?

$$R(x) = \|x\|_1 = \sum_{i=1}^d |x_i|$$

$$Rr_{\beta \|x\|_1}(p) = \operatorname{argmin}_x \left( \frac{1}{2} \sum_{i=1}^d (x_i - p_i)^2 + \beta \sum_{i=1}^d |x_i| \right) =$$

$$= \begin{pmatrix} \operatorname{argmin}_{x_1} \left( \frac{1}{2} (x_1 - p_1)^2 + \beta |x_1| \right) \\ \vdots \\ \operatorname{argmin}_{x_d} \left( \frac{1}{2} (x_d - p_d)^2 + \beta |x_d| \right) \end{pmatrix} = \left( Pr_{\beta |x_j|}(p_j) \right)_{j=1 \dots d}$$



Градиентный спуск

$$\nabla F(\theta) = -2 X^T (y - X\theta) + \beta \operatorname{sign}(\theta)$$

$$\operatorname{sign}(\theta) = (\operatorname{sign}(\theta_j))_{j=1, \dots, d}$$

$$\begin{aligned}\theta_{k+1} &= \theta_k - \eta [-2 X^T (y - X\theta_k) + \beta \operatorname{sign}(\theta_k)] = \\ &= \theta_k - \eta [2 X^T (X\theta_k - y) + \beta \operatorname{sign}(\theta_k)]\end{aligned}$$

Стох. градиентный спуск

$$\theta_{k+1} = \theta_k - \eta \frac{n}{m} \sum_{j=1}^m \left[ 2 x_{ij}^T (x_{ij} \theta_k - y_{ij}) + \beta \operatorname{sign}(\theta_k) \right]$$

$$I = \{i_1, \dots, i_m\} \sim U\{1, \dots, m\}$$

$$y \sim \mathcal{N}(\beta, \sigma^2 I_n) \quad \text{to} \quad D \hat{\theta}_{\text{Lasso}} \approx \sigma^2 (X^T X + W)^{-1} X^T X (X^T X + W)^{-1}$$

$$W = \frac{1}{\|\hat{\theta}\|_1 \cdot \|X^T \hat{\Sigma}\|_\infty}$$


$$\hat{\Sigma} = y - X\hat{\theta}$$

$$\|v\|_\infty = \max_j v_j$$

дерево

н  
н  
н

мы не влияем



5  
3

7  
1