

Bias - variance разложение

В статистике: $\hat{\theta}$ - оценка θ

$$MSE_{\hat{\theta}}(\theta) := E_{\theta}(\hat{\theta} - \theta)^2 = \underbrace{(E_{\theta} \hat{\theta} - \theta)^2}_{\text{bias}^2 \text{ смещение}} + \underbrace{D_{\theta} \hat{\theta}}_{\text{variance} \text{ разброс}}$$

Обозначения: 1) \hat{y} - случайная ф-ция $X \rightarrow Y$

Случайность может быть обусловлена:

- погрешностью при изм. отклика (случайные y_i)
- случайные признаки
- случайность модели (например, выбор случайного набора пр-ков в вершине)

2) x - неслучайный объект

y - случайный отклик, т.е. $y = f(x, \varepsilon)$,

где f - детерм. ф-ция

ε - случайный шум

\hat{y} , ε независимы

$$MSE_{\hat{y}}(x) := E(\hat{y}(x) - y)^2 = E(\hat{y}(x) - f(x, \varepsilon))^2 =$$

$$= E(\hat{y}(x) - E f(x, \varepsilon) - f(x, \varepsilon) + E f(x, \varepsilon))^2 =$$

$$= E(\underbrace{\hat{y}(x) - E f(x, \varepsilon)}_{\text{b-v разн. для оценки}})^2 + E(\underbrace{f(x, \varepsilon) - E f(x, \varepsilon)}_{\text{генерация } f(x, \varepsilon)})^2 - 2 E(\underbrace{\hat{y}(x) - E f(x, \varepsilon)}_{\text{зависит от } \hat{y}})(\underbrace{f(x, \varepsilon) - E f(x, \varepsilon)}_{\text{зависит от } \varepsilon}) =$$

$$E(f(x, \varepsilon) - E f(x, \varepsilon)) = 0$$

$$= \underbrace{(E \hat{y}(x) - E f(x, \varepsilon))^2}_{\text{bias}^2} + \underbrace{D \hat{y}(x)}_{\text{variance}} + \underbrace{D f(x, \varepsilon)}_{\text{noise}}$$

$$E(\hat{y}(x) - y)^2 = (E \hat{y}(x) - E f(x, \varepsilon))^2 + D \hat{y}(x) + D f(x, \varepsilon)$$

Следствие 1

Пусть шум аддитивен и несмещ. $f(x, \varepsilon) = h(x) + \varepsilon$

$$E\varepsilon = 0 \quad D\varepsilon = \sigma^2$$

$$\text{Тогда } E(\hat{y}(x) - y)^2 = (E\hat{y}(x) - h(x))^2 + D\hat{y}(x) + \sigma^2$$

Следствие 2

Пусть x — новый объект, но теперь он случаен

$$\text{Тогда } E(\hat{y}(x) - y)^2 = E \left[\underbrace{E((\hat{y}(x) - y)^2 | x)}_{\substack{x \text{ — фикс.} \Rightarrow \\ \text{уже посчитано}}} \right] =$$

yD

$$D(X|Y) = E(X^2|Y) - E(X|Y)^2$$

yMO

$$E(X|Y) = f(Y)$$

$$E(X|Y=y) = f(y)$$

$$E E(X|Y) = EX$$

$$E(\hat{y}(X) - Y)^2 = \left(E(\hat{y}(X)|X) - E(f(X, \varepsilon)|X)\right)^2 + E D(\hat{y}(X)|X) + E D(f(X, \varepsilon)|X)$$

Ridge - регрессия

1

Применим разложение для аддитивного несмещ. шума.

$$\hat{y}(x) = x^T \hat{\theta}$$

$$h(x) = x^T \theta$$

$$y = X\theta + \varepsilon$$

$$E\varepsilon = 0$$

$$D\varepsilon = \sigma^2 I_n$$

$$\hat{\theta} = (X^T X + \lambda I_d)^{-1} X^T y$$

$$E \hat{y}(x) = x^T E \hat{\theta} = x^T (X^T X + \lambda I_d)^{-1} X^T X \theta$$

$$D \hat{y}(x) = x^T D \hat{\theta} x = x^T (X^T X + \lambda I_d)^{-1} X^T X (X^T X + \lambda I_d)^{-1} x \sigma^2$$

$$\text{bias}^2 = (E \hat{y}(x) - h(x))^2 = \dots$$

$$\text{variance} = D \hat{y}(x) = \dots$$


МНК ($\lambda = 0$)

$$\text{bias}^2 = 0$$

$$\text{variance} = x^T (X^T X)^{-1} x \sigma^2$$

Вывод: $X^T X$ близка к вырожденной \Rightarrow в МНК расброс большой

Ridge - var < МНК - var



Смесь моделей

2

$$\hat{y}(x) = \frac{1}{T} \sum_{t=1}^T \hat{y}_t(x)$$

$$\text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{Dx Dy}}$$

~~\hat{y}_t одинаково распределены~~ $\text{cov}(\hat{y}_a, \hat{y}_b) = \text{cov}(\hat{y}_a, y_d)$

$$\text{bias}^2 = (E \hat{y}(x) - h(x))^2 = (E \hat{y}_1(x) - h(x))^2$$

т.е. смещение композиции = смещ. одной модели

$$\text{variance } D \hat{y}(x) = \frac{1}{T^2} \sum_{t_1=1}^T \sum_{t_2=1}^T \text{cov}(\hat{y}_{t_1}(x), \hat{y}_{t_2}(x)) =$$

$$= \frac{1}{T} D \hat{y}_1(x) + \frac{T-1}{T} \text{cov}(\hat{y}_1(x), \hat{y}_2(x)) =$$

$D \hat{y}_1(x) \quad \text{corr}(\hat{y}_1(x), \hat{y}_2(x))$

$$= D \hat{y}_1(x) \left[\frac{1}{T} + \frac{T-1}{T} \operatorname{corr}(\hat{y}_1(x), \hat{y}_2(x)) \right]$$

Вывод: Разброс тем меньше, тем меньше корреляция моделей.

Bagging

3

Композиция вида $\hat{y}(x) = \frac{1}{T} \sum_{t=1}^T \hat{y}_t(x)$

где \hat{y}_t построена по случ. подвыборке обучающей выборки с возвращением.

Замечание: \hat{y}_t могут быть из разных семейств (лин/дерево/—)

Частный случай — Random Forest

Bagging = $\left. \begin{array}{l} \text{bias} \text{ малое} \\ \text{variance} \text{ одной модели большой} \\ \text{corr} \text{ моделей низкая} \end{array} \right\} \Rightarrow \text{bias маленький, variance маленький}$

Как получить модели с малой корреляцией?

- разные типы моделей, разные гиперпараметры
- обучать на разных признаках
- разная предобработка данных