

## Градиентный бустинг в XGBoost

$\mathcal{F}$  - мн-во базовых моделей

Строим композицию вида:

$$\hat{y}_t(x) = \sum_{\tau=1}^t \tau_{\tau} b_{\tau}(x) = \hat{y}_{t-1}(x) + \tau_t b_t(x).$$

Пусть  $L(y, \hat{y})$  - ф-ция потерь

Функционал качества:  $Q(y, \hat{y}) = \sum_{i=1}^n L(y_i, \hat{y}(x_i))$

где  $(x_1, y_1) \dots, (x_n, y_n)$  - обуч. выборка.





Работа не волк  
Волк - это ходить,  
работа это ворк :)

не стирать!

Обид нет.  
Просто сделаны  
выводы.

Перейдем в ир-во  $\mathbb{R}^n$ .

Объекты в  $\mathbb{R}^n$

$$S \in \mathbb{R}^n$$

$$\Delta S \in \mathbb{R}^n$$

$$Q(y, S) = \sum_{i=1}^n L(y_i, s_i)$$

$$g = \nabla_S Q(y, S)$$

$$h_i = \frac{\partial^2 L(y_i, s_i)}{\partial s_i^2}$$

Таблица соотв. обозначений:

Их значения в буклете.

$$\left( \hat{y}_{t-1}(x_i) \right)_{i=1}^n$$

$$\left( \hat{b}_t(x_i) \right)_{i=1}^n$$

$$Q(y, \hat{y})$$

$$\tilde{g} = \nabla_S Q(y, \hat{y})$$

$$\tilde{h}_i = \frac{\partial^2 L(y_i, \hat{y}(x_i))}{\partial s_i^2}$$



Рассм. разложение по Тейлору  $Q(y, s + \Delta s)$  по 2-й поряд.

$$\begin{aligned}
 Q(y, s + \Delta s) &= \sum_{i=1}^n L(y_i, s_i + \Delta s_i) = \\
 &= \sum_{i=1}^n \left[ \underbrace{L(y_i, s_i)}_{\text{не зависит от } \Delta s} + \Delta s_i \cdot g_i + \frac{1}{2} \Delta s_i^2 \left( \frac{\partial^2 L(y_i, s_i)}{\partial s_i^2} \right) \right] \rightarrow \min_{\Delta s \in \mathbb{R}^n} \\
 &\quad \sum_{i=1}^n \left[ \Delta s_i \cdot g_i + \frac{1}{2} \Delta s_i^2 h_i \right] \rightarrow \min_{\Delta s \in \mathbb{R}^n}
 \end{aligned}$$

Вспомогат.,  
нрн постр  
 $\sum_{i=1}^n$   
в Тейлору  
 $\sum_{i=1}^n$   
"  
 $\sum_{i=1}^n (\Delta s_i^2 + g_i \Delta s_i)$   
Вспомог: б адр



→ min  $\Delta S \in \mathbb{R}^n$

Вспомним, что мы пытаемся найти в простом фаз. sys.  
при построении новой модели.

$$\sum_{i=1}^n (b(x_i) + \tilde{g}_i)^2 \rightarrow \min_{\tilde{g} \in \mathbb{R}^n}$$

В терминах пр.-ва  $\mathbb{R}^n$ :

$$\sum_{i=1}^n (\Delta S_i + g_i)^2 \rightarrow \min_{\Delta S \in \mathbb{R}^n}$$


$$\sum_{i=1}^n (\Delta S_i^2 + 2g_i \Delta S_i + \cancel{g_i^2}) \sim \sum_{i=1}^n \left( \Delta S_i g_i + \frac{1}{2} \Delta S_i^2 \right) \rightarrow \min_{\Delta S \in \mathbb{R}^n}$$

т.к. не зависит от  $\Delta S$

Вывод: в общем случае мы отбрасываем слагаемые о 2-й степ.  
по сути сводя задачу к линейной.



Пусть структура дерева построена.  
Выбор значения в листе.



Дерево представимо в виде:

$$b(x) = \sum_{k=1}^l \gamma_k I\{x \in R_k\},$$

где  $l$  — кол-во листьев

$\gamma_k$  — значения в листе

$R_k \subset \mathbb{R}^d$  — область, объекты которой попадают в один лист с номером  $k$ .



Работа не бак  
Бак - это ходить,  
работа это бок)

не читать

Обид нет.  
Просто сдвиги  
выбросы.

XGBoost использует две регуляризации:

1). на кол-во листьев

2). норму значений в листьях

Получаем функционал:

$$\sum_{i=1}^n \left[ \tilde{g}_i f(x_i) + \frac{1}{2} \tilde{h}_i f^2(x_i) \right] + \gamma L + \frac{\lambda}{2} \sum_{k=1}^K \tau_k^2 =$$

$$= \sum_{k=1}^L \left[ \underbrace{\gamma_k \left( \sum_{i=1}^n \tilde{g}_i I\{x_i \in R_k\} \right)}_{G_k} + \frac{1}{2} \underbrace{\gamma_k^2 \left( \sum_{i=1}^n \tilde{h}_i I\{x_i \in R_k\} + \lambda \right)}_{H_k} + \mu \right] =$$

$$= \sum_{k=1}^L \left[ \gamma_k G_k + \frac{1}{2} \gamma_k^2 (H_k + \lambda) + \mu \right] \rightarrow \min_{\gamma_k}.$$

$$\gamma_k = \frac{-G_k}{H_k + \lambda}$$

Задача разбивается на подзадачи по отдельным листьям.  
— оптимальное значение в листе.




$$+ \mu] =$$

Критерий информативности.

Подставим опт.  $\gamma_k$  в исходную ф-лу:

$$Q^* = \sum_{k=1}^l \left( \frac{G_k^2}{H_k + \lambda} + \frac{1}{2} \frac{G_k^2}{(H_k + \lambda)^2} (H_k + \lambda) + \mu \right) =$$

$$= \sum_{k=1}^l \left[ -\frac{1}{2} \frac{G_k^2}{H_k + \lambda} + \mu \right] = \sum_{k=1}^l H(R_k)$$



$$H(X_m) - H(X_e) - H(X_z) \rightarrow \min$$

Критерий информ.