

Св-ва оценок в модели лн. регр.

3.3

при несмещ. и юмскедастичности шума

Предполагаемая зависимость

$$y(x) = \theta^T x$$

Наблюдаемая зависимость

$$y(x) = x\theta + \varepsilon$$

$y \in \mathbb{R}^n$	$x \in \mathbb{R}^{n \times d}$	$\theta \in \mathbb{R}^d$	$\varepsilon \in \mathbb{R}^n$
\uparrow	\uparrow	\uparrow	\uparrow
случ.	известен неслуч.	неизв.	случ. неизв.

Задача: оценить θ

$$\underset{\substack{\text{residual sum} \\ \text{of squares}}}{RSS(\theta)} = \sum_{i=1}^n (y_i - \theta^T x_i)^2 = \|y - X\theta\|^2$$

$$\hat{\theta} = \underset{\theta \in \mathbb{R}^n}{\operatorname{argmin}} RSS(\theta) \quad - \quad \begin{array}{l} \text{МНК} \\ \text{оценка} \end{array}$$

$$\text{Если } X^T X \text{ - не вып., то } \hat{\theta} = (X^T X)^{-1} X^T Y$$

Свойства:

1) Если $E\varepsilon = 0$, то $E\hat{\theta} = \theta$

$$E\hat{y}(x) = y(x), \text{ где } \hat{y}(x) = \hat{\theta}^T x$$

[несмещённость шума]

2) Если $D\varepsilon = \sigma^2 I_n$, $E\varepsilon = 0$, то

$$D\hat{\theta} = \sigma^2 (X^T X)^{-1}$$

$$\det(X^T X) \sim 0$$

\Rightarrow

большая дисперсия

\Rightarrow больно

$$D\hat{y}(x) = \sigma^2 x^T (X^T X)^{-1} x$$

[гомоскедастичность шума]

$$\blacktriangle E \hat{\theta} = E((X^T X)^{-1} X^T Y) = (X^T X)^{-1} X^T E(X\theta + \varepsilon) =$$

$$= (X^T X)^{-1} X^T X \theta = \theta$$

$$\underbrace{D}_{n \times d} \underbrace{A}_{d \times 1} \underbrace{\xi}_{1 \times 1} = \underbrace{A}_{n \times d} \underbrace{D}_{d \times d} \underbrace{\xi}_{d \times 1} \underbrace{A^T}_{d \times n}$$

$$D \hat{\theta} = D((X^T X)^{-1} X^T Y) = (X^T X)^{-1} X^T D(X\theta + \varepsilon) \quad X(X^T X)^{-1} =$$

$$= (X^T X)^{-1} \sigma^2 I_n X^T X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$$

УТВ. Если $E\varepsilon = 0$ $D\varepsilon = \sigma^2 I_n$, то

оценка $\hat{\sigma}^2 = \frac{RSS(\hat{\theta})}{n-d} = \frac{\|y - X\hat{\theta}\|^2}{n-d}$ — наименьш. оценка σ^2

$$\blacktriangle E RSS(\hat{\theta}) = E \sum_{i=1}^n (y_i - \hat{\theta}^T x_i)^2 = D \sum_{i=1}^n (y_i - \hat{\theta}^T x_i) =$$

$$\left[E (y_i - \hat{\theta}^T x_i) = 0 \right]$$

\parallel
 $\theta^T x_i + \varepsilon$

$$= \text{tr } D(y - X\hat{\theta})$$

$$D(y - X\hat{\theta}) = D \left[\left(I_n - \underbrace{X(X^T X)^{-1} X^T}_{A - \text{симметр.}} \right) y \right] = D[(I_n - A)y] =$$

$\left[\begin{array}{l} A \text{ обратима} \Rightarrow \varepsilon \equiv 0 \\ n < d \Rightarrow \text{rk } A < n \Rightarrow A \text{ необратима} \end{array} \right.$

$$= (I_n - A) D y (I_n - A)^T = (I_n - A) \sigma^2 I_n (I_n - A)^T =$$

$$= \sigma^2 (I_n - A^T - A + A A^T) =$$

$$\left[A A^T = X \cancel{(X^T X)^{-1}} X^T \cancel{X} (X^T X)^{-1} X^T = A \right]$$

$$= \sigma^2 I_n (I_n - A)$$

$$\left[\text{tr } A = \text{tr} \left(X \underset{\substack{\uparrow \\ \text{св-во слега}}}{(X^T X)^{-1}} X^T \right) = \text{tr} \left(X^T X (X^T X)^{-1} \right) = \text{tr}(I_d) = d \right]$$

$$\Rightarrow \text{tr } D(y - X\hat{\theta}) = \text{tr}(\sigma^2 (I_n - A)) = \sigma^2 (n - d)$$

Пример

$$X_1, \dots, X_n \sim \text{Exp}(\theta)$$

$$\hat{\theta}_1 = 1/\bar{x}$$

$$\hat{\theta}_2 = -\ln \overline{I\{X > 1\}}$$

Какая лучше?

[когда-то было]

сильность,
и ас. норм.
оценки θ

Сравнение оценок

3.4

Хотим оценить $\tau(\theta) \in \mathbb{R}^d$

Опр. Ф-ция $L: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}_+$, характеризующая степень отклонения оценки от $\tau(\theta)$ наз-ся **функцией потерь**

Примеры: 1) $d=1$ $L(x, y) = (x - y)^2$ - квадратичная



2) $d=1$ $L(x, y) = |x - y|$ - абсолютная



3) $d=1$ $L(x, y) = \ln(1 + |x - y|)$



$$4) \quad d > 1 \quad L(x, y) = (x - y)^T A (x - y),$$

где A — сим. неотр. полуопр.

$$A = I_d, \quad \text{тогда} \quad h(x, y) = \sum_{i=1}^d (x_i - y_i)^2$$

Если $\hat{\theta}$ — оценка $\tau(\theta)$, то при таком оценивании

$L(\hat{\theta}, \tau(\theta))$ — штраф

При таком подходе есть недостаток:

штраф случаен, при разных реализациях получаем разные штрафы

Опр. φ -функция риска оценки $\hat{\theta}$ величины $\tau(\theta)$

$$R_{\hat{\theta}, \tau(\theta)}(\theta) = E_{\theta} L(\hat{\theta}, \tau(\theta)) \leftarrow \varphi\text{-функция от } \theta$$

(risk function)

Если $L(x, y) = (x - y)^2$ - кв. ф-ция потерь, то

$MSE_{\hat{\theta}, \tau(\theta)} = E_{\theta} (\hat{\theta} - \tau(\theta))^2$ - средняя квадратичная ошибка

$MAE_{\hat{\theta}, \tau(\theta)} = E_{\theta} |\hat{\theta} - \tau(\theta)|$ - средняя абсолютная ошибка

Замечание:




Если $\tau(\theta) = \theta$, то τ будем опускать

Пример X_1, \dots, X_n — выборка $E X_1 = \theta$
 $D X_1 < +\infty$

Посчитаем MSE для X_1, \bar{X} — оц. θ
 $\hat{\theta}_1, \hat{\theta}_2$

$$MSE_{\hat{\theta}_1}(\theta) = E_{\theta} (X_1 - \underbrace{\theta}_{EX_1})^2 = DX_1$$

$$MSE_{\hat{\theta}_2}(\theta) = E_{\theta} (\bar{X} - \underbrace{\theta}_{E\bar{X}})^2 = D\bar{X} = \frac{DX_1}{n}$$



Что лучше?

Подход к сравнению оценок

1) Равномерный подход

- $\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\forall \theta \in \Theta \quad R_{\hat{\theta}_1}(\theta) \leq R_{\hat{\theta}_2}(\theta)$

- $\hat{\theta}_1$ лучше $\hat{\theta}_2$, если $\hat{\theta}_1$ не хуже $\hat{\theta}_2$

и $\exists \theta \in \Theta \quad R_{\hat{\theta}_1}(\theta) < R_{\hat{\theta}_2}(\theta)$


- $\hat{\theta} \in \mathcal{K}$ — класс оценок, $\hat{\theta}$ — наилучшая в \mathcal{K} , если она лучше любой другой

- Если $L(x, y) = (x - y)^2$ — ф-ция потерь

то говорят о среднеквадратичном подходе

Утв. В классе \mathcal{K} может не быть наилучшей оценки.

Пример $\Theta = \mathbb{R}$ $\mathcal{K} = \{ \hat{\theta}_1 = 1, \hat{\theta}_2 = 2 \}$



Утв. MSE допускает bias-variance разложение

$$\text{MSE}_{\hat{\theta}, \tau}(\theta) = E_{\theta}(\hat{\theta} - \tau(\theta))^2 = \underbrace{D\hat{\theta}}_{\text{variance}} + \underbrace{(E_{\theta}\hat{\theta} - \tau(\theta))^2}_{\text{bias}^2}$$

Следствие:

наилучший по MSE в классе $\mathcal{K} = \{\text{несмещ. оц.}\}$ будет


оценка с наим дисперсией

$$\begin{aligned} \rightarrow \triangle E_{\theta}(\hat{\theta} - \tau(\theta))^2 &= \underbrace{E_{\theta}(\hat{\theta} - E_{\theta}\hat{\theta})^2}_{D\hat{\theta}} + \underbrace{E(E_{\theta}\hat{\theta} - \tau(\theta))^2}_{\text{const}} + 2 \underbrace{E_{\theta}(\hat{\theta} - E_{\theta}\hat{\theta})}_{0 \text{ т.к. несмещ.}} \underbrace{(E_{\theta}\hat{\theta} - \tau(\theta))}_{\text{const}} = \\ &= D\hat{\theta} + (E_{\theta}\hat{\theta} - \tau(\theta))^2 \end{aligned}$$

2) Байесовский подход

Пусть Q - распределение на Θ

- $\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $E_Q R_{\hat{\theta}_1, \tau}(\theta) \leq E_Q R_{\hat{\theta}_2, \tau}(\theta)$



$$Q = U[0, 1]$$

при таком Q мы по факту считаем
интеграл

$\hat{\theta}_2$ лучше $\hat{\theta}_1$

3) Минимаксный подход

- $\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\sup_{\theta \in \Theta} R_{\hat{\theta}_1}(\theta) \leq \sup_{\theta \in \Theta} R_{\hat{\theta}_2}(\theta)$

4) Асимптотический подход (для ас. норм. оц., \mathbb{R})

$\hat{\theta}_1, \hat{\theta}_2$ — а.н.о. с ас.г. σ_1^2, σ_2^2

- $\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\forall \theta \in \Theta \quad \sigma_1^2(\theta) \leq \sigma_2^2(\theta)$
- $\hat{\theta}_1$ лучше $\hat{\theta}_2$, если $\downarrow \quad + \quad \exists \theta \in \Theta \quad \sigma_1^2(\theta) < \sigma_2^2(\theta)$

- $ARE_{\hat{\theta}_1, \hat{\theta}_2}^{\tau} = \frac{\sigma_2^2(\theta)}{\sigma_1^2(\theta)}$

относительная асимптотическая
эффективность
показывает насколько $\hat{\theta}_1$ лучше $\hat{\theta}_2$

Опр $\hat{\theta}$ наз-ся асимптотически эффективной, если она наилучшая
в классе всех а.н.о. с [↑]непр. а.д. в асимпт. подходе
вроде без непр не будет наилуч. оц. в классе

[т.е. наим. ас. дисп. среди всех а.н.о.]

[L1 - L9] ОМП - ас. эф. оценка, т.е. $i(\theta)^{-1}$ - наим ас. д.

матрички сравнивать страшно
этого мы делать не будем

Пример

$$X_1, \dots, X_n \sim N(\theta, 1)$$

и/б здесь $\frac{\pi^2}{4}$

ЦПТ: \bar{X} — а.н.о. θ с а.г. $\sigma^2(\theta)$

т. о. выборочной медиане $\hat{\mu}$ — а.н.о. θ с а.г. $\sigma_2^2(\theta) = \frac{\pi}{2}$

$ARE_{\bar{X}, \mu} = \frac{\pi}{2} \approx 1.57$, т.е. \bar{X} в ~ 1.57 раза лучше μ

Пример $X_1, \dots, X_n \sim \text{Exp}(\theta)$

[раньше было] $\hat{\theta}_1 = \frac{1}{\bar{X}}$ а.н.о. с а.г. $\sigma_1^2(\theta) = \theta^2$
 $\hat{\theta}_2 = -\ln \overline{I\{X > 1\}}$ а.н.о. с а.г. $\sigma_2^2(\theta) = e^\theta - 1$

$$\text{ARE}_{\hat{\theta}_1, \hat{\theta}_2} = \frac{e^\theta - 1}{\theta^2}$$

Достаточные статистики

3.5

Опр Пусть $X = (X_1, \dots, X_n)$ — выборка из $P \in \mathcal{P}$

Статистика $S(X)$ наз-ся **достаточной** для семейства \mathcal{P} ,

если условное распр. $P_\theta(X \in B \mid S(X))$ не зависит от $\theta \forall B$

Смысл: вся информация о θ , содержащаяся в выборке
содержится в достаточной статистике

Тривиальный пример: $S(X) = (X_1, \dots, X_n)$

Следствие: Если данные поступают последовательно, то достаточно
хранить только $S(X)$

Важным является случай, когда размерность достаточной статистики меньше размера выборки. $|S(x)| \ll n$

[на самом деле такое $S(x)$ не всегда суц.]
например для распр. Коши

Пример $X_1, \dots, X_n \sim \text{Bern}(\theta)$

Какая информация есть в выборке?

кол-во успехов $S(x) = \sum_{i=1}^n x_i$

Порядок успех-неудач (какой-то упорядоченный порядок без количеств)

$S(x)$ — достаточная

$$\blacktriangle P_{\theta}(X = \bar{x} \mid S(x) = s) = \frac{P_{\theta}(X_1 = x_1, \dots, X_n = x_n, \sum X_i = s)}{P_{\theta}(\sum X_i = s)} = \begin{cases} \text{если } \sum x_i \neq s \\ \text{то } 0 \end{cases}$$

$$= \frac{\theta^{\sum x_i} (1-\theta)^{n-\sum x_i} I\{\sum x_i = s\}}{\theta^s (1-\theta)^{n-s} C_n^s} = \frac{I\{\sum x_i = s\}}{C_n^s} \leftarrow \text{не зависит от } \theta$$

Теор. (Критерий факторизации Неймана - Фишера)

Пусть $X = (X_1, \dots, X_n)$ — выборка из распр $P \in \mathcal{P}$ — домин. семейство

Тогда $S(X)$ — дос. стат. \Leftrightarrow справедлива факторизация

$$p_{\theta}(X) = \psi(S(X), \theta) \cdot \underbrace{h(X)}_{\text{не зависит от } \theta}$$

Пример $X_1, \dots, X_n \sim \Gamma(\alpha, \beta) \quad \theta = (\alpha, \beta)$

$$p_{\theta}(x) = \frac{\alpha^{\beta}}{\Gamma(\beta)} x^{\beta-1} e^{-\alpha x}$$

$$p_{\theta}(x_1, \dots, x_n) = \frac{\alpha^{\beta n}}{\Gamma(\beta)^n} \left(\prod_{i=1}^n x_i \right)^{\beta-1} e^{-\alpha \sum x_i} = \underbrace{\psi(\underbrace{S(x)}_{\text{статистика}}, \underbrace{\theta}_{\text{параметры}})}_{\text{функция правоподобия}} \cdot h(x)$$

$$h(x) = 1$$

$$S(x) = (\sum x_i, \prod x_i)$$

$$S(x) = (\sum x_i, \sum \ln x_i)$$

$$\psi(x, y, \alpha, \beta) = \frac{\alpha^{\beta n}}{\Gamma(\beta)^n} y^{\beta-1} e^{-\alpha x}$$



достаточные
статистики