

②

Энтропия и дивергенция (дискр. случай)

7.1

Пусть P - распр, т.е. символы $\{a_1, \dots, a_k\}$ имеют вероятности $\{p_1, \dots, p_k\}$

$$H(P) = - \sum_{j=1}^k p_j \log p_j \quad \text{— энтропия}$$

Утв.

$$1) \quad H(P) \geq 0 \quad = 0 \Leftrightarrow \exists j: p_j = 1 \quad (0 \log 0 = 0)$$

$$2) \quad H(P) \leq \log k \quad = \log k \Leftrightarrow \forall j \quad p_j = 1/k$$

▲

$$1) \quad \text{следует из того, что } -\log p_j \geq 0$$

$$2) \quad H(P) = E \log \frac{1}{p(\zeta)} \leq \log E \frac{1}{p(\zeta)} = \log \sum_{j=1}^k p_j \frac{1}{p_j} = \log k$$

где $\zeta \sim P$ ↑
по нер-ву Йенсена

□

Общий случай

P, Q - доминиру.

$$H(P) = -E \log p(\xi), \quad \text{где } \xi \sim P$$

энтропия

$$H(P, Q) = -E \log q(\xi), \quad \text{где } \xi \sim P$$

кросс-энтропия

$$KL(P, Q) = H(P, Q) - H(P) = E \log \frac{p(\xi)}{q(\xi)}, \quad \text{где } \xi \sim P$$

дивергенция

Пример

$$P = U(0, 1/2)$$

$$p(x) = 2 \cdot \mathbb{I}_{x \in (0, 1/2)}$$

$$H(P) = -\log 2 < 0$$

Свойства KL :

$$1) \quad KL(P, Q) \geq 0 \quad = 0 \Leftrightarrow P = Q$$

$$\begin{aligned} \blacktriangle \quad -KL(P, Q) &= E \log \frac{q(\xi)}{p(\xi)} \stackrel{\text{Йенсен}}{\leq} \log E \frac{q(\xi)}{p(\xi)} = \log \int p(x) \frac{q(x)}{p(x)} dx = \\ &= \log 1 = 0 \end{aligned}$$

т.к. \log — строго выпуклый, то равенство достигается при $P=Q$

$$2) \quad KL(P, Q) \neq KL(Q, P)$$

3) Пусть x_1, \dots, x_n — выборка из $P_\theta \in \{P_\theta \mid \theta \in \Theta\}$ — дискретное

$$KL(\hat{P}_n, P_\theta) = E_{\hat{P}_n} \log \frac{\hat{p}_n(x)}{p_\theta(x)} = \frac{1}{n} \sum_{i=1}^n \log \frac{1/n}{p_\theta(x_i)} =$$

дискр. н.г.н. \rightarrow

$$= -\frac{1}{n} \sum_{i=1}^n \log p_{\theta}(x_i) - \log n = -\frac{1}{n} l_x(\theta) - \log n$$

Barlog: $KL(\hat{P}_n, P_{\theta}) \rightarrow \min_{P_{\theta}} \Leftrightarrow l_x(\theta) \rightarrow \max_{\theta}$

Теорема Экстремальное свойство правдоподобия [L1-L3]

$$\forall \theta_0, \theta_1 \in \Theta \text{ т.ч. } \theta_0 \neq \theta_1 \quad P_{\theta_0}(L_X(\theta_0) > L_X(\theta_1)) \rightarrow 1 \text{ при } n \rightarrow \infty$$

$$L_X(\theta_0) > L_X(\theta_1) \Leftrightarrow \frac{L_X(\theta_0)}{L_X(\theta_1)} > 1 \Leftrightarrow \frac{1}{n} \log \frac{L_X(\theta_0)}{L_X(\theta_1)} > 0$$

$$\frac{1}{n} \log \frac{L_X(\theta_0)}{L_X(\theta_1)} = \frac{1}{n} \log \prod_{i=1}^n \frac{p_{\theta_0}(x_i)}{p_{\theta_1}(x_i)} = \frac{1}{n} \sum_{i=1}^n \log \frac{p_{\theta_0}(x_i)}{p_{\theta_1}(x_i)} \xrightarrow[\text{ЗЗЗ}]{P_{\theta_0}^{-n,n.}}$$

$$\rightarrow E_{\theta_0} \log \frac{p_{\theta_0}(x_i)}{p_{\theta_1}(x_i)} = KL(P_{\theta_0}, P_{\theta_1}) > 0$$

↑
т.ч. $\theta_0 \neq \theta_1$ и L1

Получаем $P_{\theta_0}(L_X(\theta_0) > L_X(\theta_1)) \rightarrow P(KL(P_{\theta_0}, P_{\theta_1}) > 0) = 1$

Следствие: Если $|\Theta| < \infty$, то ОМП существует и явл. сог. оц.

[L1 - L3]

Δ Пусть θ_0 — истинное знач. парам.

Тогда $P_{\theta_0} (\forall \theta_1 \neq \theta_0 : L_X(\theta_0) > L_X(\theta_1)) =$

$$= P_{\theta_0} \left(\bigcap_{k=1}^{|\Theta| \leftarrow \text{конечное}} L_X(\theta_0) > L_X(\theta_k) \right) \rightarrow 1$$

Теорема С вер-тью $\rightarrow 1$ ур-е $\frac{\partial L_x(\theta)}{\partial \theta} = 0$ имеет корень, являющийся
сост. оц. θ


[L1 - L5]

▲ Пусть θ_0 - истинное значение параметра

L4 $\Rightarrow \exists \varepsilon > 0$ т.ч. $(\theta_0 - \varepsilon, \theta_0 + \varepsilon) \subset \Theta$

По т. об экстр. св-ве:

$$P_{\theta_0} (L_x(\theta_0) > L_x(\theta_0 - \varepsilon), L_x(\theta_0) > L_x(\theta_0 + \varepsilon)) \rightarrow 1$$



с вер $\rightarrow 1$

\Rightarrow с вер $\rightarrow 1$ на $(\theta_0 - \varepsilon, \theta_0 + \varepsilon)$ имеется корень ур-я правдоподобия.

Пусть $\tilde{\theta}_0$ — ближайший к θ_0 корень ур-я (не факт, что $\tilde{\theta}_0 \in (\theta_0 - \varepsilon; \theta_0 + \varepsilon)$)


Тогда $P(|\tilde{\theta} - \theta_0| > \varepsilon) \rightarrow 0$

Т.к. это выполнено $\forall \varepsilon > 0$, то получаем, что

$\tilde{\theta} \xrightarrow{P_{\theta_0}} \theta_0 \Rightarrow \tilde{\theta} - \text{сост. оц. } \theta \quad \square$

Следствие [L1-L5] Если $\forall n \forall x_1, \dots, x_n \frac{\partial l_n(\theta)}{\partial \theta} = 0$ имеет единственный корень,
то $\tilde{\theta}$ — соед. оц. θ

$$P(\tilde{\theta} = \hat{\theta}_{\text{МП}}) = 1 \Rightarrow \hat{\theta}_{\text{МП}} - \text{соед.}$$



Теорема [11-19]

1) $\tilde{\theta}$ — сост. оц. θ , являющаяся решением ур-я правдоподобия

Тогда $\tilde{\theta}$ — а.н.о. θ с а.р. $i^{-1}(\theta)$

В частности, если $\tilde{\theta}$ — ед. реш. ур-я правдоподобия,

Тогда $\tilde{\theta}$ — а.н.о. θ с а.р. $i^{-1}(\theta)$

2) Пусть $\hat{\theta}$ — а.н.о. с а.р. $\sigma^2(\theta)$, т.е. $\sigma^2(\theta)$ невр. по θ

Тогда $\sigma^2(\theta) \geq i^{-1}(\theta)$ (5/9)

Следствие ОМП — сост., а.н.о., асимптотически эффективно
[11-19] (т.е. имеет наиб. а.р. среди всех а.н.о. с невр. дисп.)

Примечание если $L1-L9$ нету, то можно получить более крутые св-ва.

$$X_1, \dots, X_n \sim \mathcal{U}[0, \theta]$$

$$n(\theta - X_{(n)}) \xrightarrow{d} \text{Exp}(1) \quad \leftarrow \text{это крутые ас. нормы}$$

$$(X_{(n)} \pm \underline{c/n})$$

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N$$

$$(\hat{\theta} \pm \underline{c/\sqrt{n}})$$

Док-во п. 1)

Вклад $u_x(\theta) = \frac{\partial L_x(\theta)}{\partial \theta}$

разложим по Тейлору $u_x(\tilde{\theta})$ в точке θ : (в форме Лагранжа)

$$u_x(\tilde{\theta}) = u_x(\theta) + u'_x(\theta)(\tilde{\theta} - \theta) + \frac{1}{2} u''_x(\theta^*) (\tilde{\theta} - \theta)^2$$

где θ^* лежит между $\tilde{\theta}$ и θ

следствие: $\theta^* \xrightarrow{P_\theta} \theta$ т.к. $\tilde{\theta} \xrightarrow{P_\theta} \theta$ $\left[\theta^* \text{ не сост. оц., т.к. не франкт, что оц., т.к. может зависеть от } \theta \right]$

$$u_x(\tilde{\theta}) = 0, \text{ т.к. } \tilde{\theta} - \text{решение ур-я } u_x(\theta) = 0$$

$$\Rightarrow -u_x(\theta) = (\tilde{\theta} - \theta) \left(u'_x(\theta) + \frac{1}{2} u''_x(\theta^*) (\tilde{\theta} - \theta) \right)$$

$$\frac{-\sqrt{n} u_x(\theta)}{u'_x(\theta) + \frac{1}{2} u''_x(\theta^*) (\tilde{\theta} - \theta)} = \sqrt{n} (\tilde{\theta} - \theta)$$

$$\frac{-\sqrt{n} u_x(\theta) \frac{1}{\sqrt{n}}}{\frac{1}{\sqrt{n}} u'_x(\theta) + \frac{1}{2\sqrt{n}} u''_x(\theta^*) (\tilde{\theta} - \theta)} \rightarrow N(0, i(\theta)) \rightarrow N(0, i'(\theta))$$

$\searrow i(\theta)$
 $\nearrow \infty$
 $\searrow 0$

$$1) \quad \sqrt{n} \frac{1}{n} u_x(\theta) = \sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n u_{x_i}(\theta) - \overbrace{E_\theta u_{x_i}(\theta)}^0 \right) \xrightarrow[\text{зпт}]{d_\theta} N(0, D_\theta u_{x_i}''(\theta))$$

$$2) \quad \frac{1}{n} u'_x(\theta) = \frac{1}{n} \sum_{i=1}^n u'_{x_i}(\theta) \xrightarrow[\text{зпт}]{P_\theta} E_\theta u'_{x_i}(\theta) = -i(\theta)$$

$$3) \quad \tilde{\theta} - \theta \xrightarrow{P_\theta} 0 \Rightarrow \text{хотим} \quad \left| \frac{1}{n} u''_x(\theta^*) \right| \leq c$$

$$\left| \frac{1}{n} u_x''(\theta^*) \right| \leq \frac{1}{n} \sum_{i=1}^n \left| u_{x_i}''(\theta^*) \right| \leq \frac{1}{n} \sum_{i=1}^n H(x_i) \xrightarrow{P_\theta} E_\theta H(x_i) < +\infty$$

где $\theta^* \in (\theta - c; \theta + c)$ по ЛГ

$$\text{т.к. } \theta^* \xrightarrow{P_\theta} \theta, \text{ то } P_\theta(\theta^* \in (\theta \pm c)) \rightarrow 1$$

$$\Rightarrow \frac{1}{n} u_x''(\theta) \text{ с.в. с. бер.} \rightarrow 1$$

$$\text{т.е. } \exists c(\theta) \forall \theta : P_\theta \left(\left| \frac{1}{n} u_x''(\theta) \right| \leq c(\theta) \right) \rightarrow 1$$

2) без гон-ба

Натуральный градиент

7.3

Пример

$$x_1, \dots, x_n \sim \mathcal{N}(a, s) \quad // \quad s = \sigma^2$$

$$L_x(\theta) = -\frac{n}{2} \log 2\pi - \frac{n}{2} \log s - \frac{1}{2s} \sum_{i=1}^n (x_i - a)^2$$

$$\frac{\partial L_x(\theta)}{\partial a} = -\frac{1}{s} \sum_{i=1}^n (a - x_i) = \frac{n}{s} (\bar{x} - a)$$

$$\frac{\partial L_x(\theta)}{\partial s} = -\frac{n}{2s} + \frac{1}{2s^2} \sum_{i=1}^n (x_i - a)^2 = \frac{n}{2s^2} \left(\frac{1}{n} \sum_{i=1}^n (x_i - a)^2 - s \right)$$

Градиентный спуск:

$$a_{t+1} = a_t + \eta_1 \bar{x} - a$$

← ответ для a

$$s_{t+1} = s_t + \eta_2 \left(\frac{1}{n} \sum_{i=1}^n (x_i - a_t)^2 - s_t \right)$$

← ответ для s

это-то ухудшающее сходимость

Пусть $f: \mathbb{R}^d \rightarrow \mathbb{R}$

$$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_j} \right)_j$$

$$\frac{\partial f(x)}{\partial x_j} = \lim_{\Delta x_j \rightarrow 0} \frac{f(x + e_j \Delta x_j) - f(x)}{\Delta x_j}$$

$\nabla f(x)$



$$\operatorname{argmax}_{\Delta x_j} (f(x + \Delta x) - f(x))$$

$$\|\Delta x\| \leq \varepsilon$$

направление наискорейшего роста

Пусть $P_\theta \in \{P_\theta \mid \theta \in \Theta\}$

$f(P_\theta)$ — функционал, напр $L_X(\theta)$


Проблема взятия производной:

окрестность $\|\Delta\theta\| \leq \varepsilon$ не отражает схожесть распределений

Пример (на проблеме выше)
1) $N(\theta_1, \theta_2)$

$$\theta = (0, 1) \quad \Delta\theta = (1, 0) \quad \|\Delta\theta\| = 1$$


$$P_\theta = N(0, 1) \quad P_{\theta + \Delta\theta} = N(1, 1)$$



$$2) \quad N(\theta_1, \theta_2) \quad \theta = (0, 100) \quad \Delta\theta = (1, 0) \quad \|\Delta\theta\| = 1$$

$$P_\theta = N(0, 100)$$

$$P_{\theta + \Delta\theta} = N(1, 100)$$



Идея: в опр. град заменим $\|\Delta\theta\| < \epsilon$ на окр-ть в пр-ве распр

Опр. Натуральный градиент

$$\nabla_N f(P_\theta) \sim \underset{\substack{\Delta \theta_j \\ \text{KL}(P_\theta, P_{\theta+\Delta\theta}) < \varepsilon}}{\operatorname{argmax}} \left[f(P_{\theta+\Delta\theta}) - f(P_\theta) \right]$$

Распишем Лагранжиан:

$$L = f(P_{\theta+\Delta\theta}) - f(P_\theta) - \lambda (\text{KL}(P_\theta, P_{\theta+\Delta\theta}) - \varepsilon)$$

$$\nabla_{\Delta\theta} L \Big|_{\Delta\theta=0} = \underbrace{\nabla_{\Delta\theta} f(P_{\theta+\Delta\theta}) \Big|_{\Delta\theta=0}}_{\nabla_\theta f(P_\theta)} - \lambda \nabla_{\Delta\theta} \text{KL}(P_\theta, P_{\theta+\Delta\theta}) \Big|_{\Delta\theta=0}$$

$\nabla_\theta f(P_\theta)$
т.е. обычный
градиент

Упр.

При $\|\Delta\theta\| \rightarrow 0$

$$KL(P_\theta, P_{\theta+\Delta\theta}) = \frac{1}{2} \Delta\theta^T \overset{\text{инф. матрица Фишера}}{i(\theta)} \Delta\theta + o(\|\Delta\theta\|^2)$$

Разложим KL по Теореме в $\Delta\theta = 0$

$$KL(P_\theta, P_{\theta+\Delta\theta}) = \underbrace{KL(P_\theta, P_\theta)}_0 + \underbrace{\nabla_{\Delta\theta} KL(P_\theta, P_{\theta+\Delta\theta})|_{\Delta\theta=0}}_0^T \cdot \Delta\theta + \\ + \frac{1}{2} \Delta\theta^T \nabla_{\Delta\theta}^2 KL(P_\theta, P_{\theta+\Delta\theta})|_{\Delta\theta=0} \cdot \Delta\theta + o(\|\Delta\theta\|^2)$$

0, т.к. это произв. в точке минимума

$$\nabla_{\Delta\theta}^2 KL(P_\theta, P_{\theta+\Delta\theta})|_{\Delta\theta=0} = \int P_\theta(x) \nabla_{\Delta\theta}^2 \log \frac{p_\theta(x)}{p_{\theta+\Delta\theta}(x)} \Big|_{\Delta\theta=0} dx =$$

$$= - \int P_\theta(x) \underbrace{\nabla_{\Delta\theta}^2 \log p_\theta(x)}_{\nabla_\theta^2 \log p_\theta(x)} \Big|_{\Delta\theta=0} dx = - E_\theta \nabla_\theta^2 \log p_\theta(x) = i(\theta)$$

Вернёмся к Лагранжиану

$$\nabla_{\Delta\theta} L = \nabla_{\theta} f(P_{\theta}) - \lambda \dot{\iota}(\theta) \Delta\theta = 0$$

$$\Rightarrow \Delta\theta = \underbrace{\frac{1}{\lambda}}_{\text{на это можно забыть, т.к. натуральный градиент используется в град. спуске}} \dot{\iota}^{-1}(\theta) \nabla_{\theta} f(P_{\theta})$$

на это можно забыть, т.к. натуральный градиент используется в град. спуске \Rightarrow там есть learning-rate

$$\text{Или } \nabla_N f(P_{\theta}) = \dot{\iota}^{-1}(\theta) \nabla_{\theta} f(P_{\theta}) \quad \text{— натуральный градиент}$$

Применим к **примеру** с нормальной выборкой:

Из семинара $i(\theta) = \begin{pmatrix} 1/s & 0 \\ 0 & 1/2s^2 \end{pmatrix} \Rightarrow i^{-1}(\theta) = \begin{pmatrix} s & 0 \\ 0 & 2s^2 \end{pmatrix}$

Рассчитываем градиентный спуск:

$$a_{t+1} = a_t + \eta_1 (\bar{x} - a_t) = \eta_1 \bar{x} + (1 - \eta_1) a_t$$

$$s_{t+1} = s_t + \eta_2 \left(\frac{1}{n} \sum_{i=1}^n (x_i - a_t)^2 - s_t \right) = \eta_2 \left(\frac{1}{n} \sum_{i=1}^n (x_i - a_t)^2 \right) + (1 - \eta_2) s_t$$

Логистическая регрессия

$$\nabla l_y(\theta) = x^T (y - s(\theta))$$

$$I(\theta) = x^T V(\theta) x$$

$$\theta_{t+1} = \theta_t + \eta (x^T V(\theta_t) x)^{-1} x^T (y - s(\theta_t))$$

IRLS

метод 1-го порядка в пр-ве распределений

метод 2-го порядка в пр-ве признаков